

Author

Scampini Riccardo

Ghezzi Samuele

Unsupervised Learning - Seeds Dataset

- Applicazione dell'algoritmo K-Means
- Dataset "Seeds" da UCI Repository

Il Dataset Seeds

Il dataset Seeds dell'**UCI Machine Learning Repository** contiene **210 campioni** di tre varietà di grano — **Kama, Rosa e Canadian** — con **70 campioni per classe** e **nessun valore mancante**.

area

mean 14.85
std 2.91
min-max 10.59–21.18
count 210
missing 0

perimeter

mean 14.56
std 1.31
min-max 12.41–17.25
count 210
missing 0

compactness

mean 0.87
std 0.024
min-max 0.8081–0.9183
count 210
missing 0

length_kernel

mean 5.63
std 0.44
min-max 4.899–6.675
count 210
missing 0

width_kernel

mean 3.26
std 0.38
min-max 2.63–4.033
count 210
missing 0

asymmetry_coefficient

mean 3.70
std 1.50
min-max 0.7651–8.456
count 210
missing 0

length_kernel_groove

mean 5.41
std 0.49
min-max 4.519–6.55
count 210
missing 0

ML Pipeline API in Flask – Architettura del Progetto

Programmazione Orientata agli Oggetti

Ogni fase della pipeline è incapsulata in una classe Python dedicata.

Architettura Modulare

Separazione netta tra caricamento, analisi, trasformazione e clustering.

Flask Blueprints

Gli endpoint REST sono organizzati come moduli indipendenti e mantenibili.

Design API RESTful

Struttura coerente degli endpoint per l'esecuzione e l'ispezione della pipeline.

Gestione Pipeline basata su UUID

Ogni istanza della pipeline è tracciata con un identificatore univoco.

Scikit-Learn

Utilizzato per preprocessing, PCA e workflow di clustering K-Means.

Docker

Esecuzione containerizzata per portabilità e riproducibilità.

Pipeline Data Science Riproducibile

Progettata per risultati coerenti, tracciabilità e workflow di livello ricerca.

EDA

La Pipeline del progetto

01

Caricamento Dataset

02

EDA

03

Rilevamento Outlier (IQR)

04

Feature Engineering

05

Robust Scaling

06

Riduzione Dimensionale




07

Clustering K-Means

08

Valutazione e Confronto

Exploratory Data Analysis



L'analisi esplorativa ha evidenziato **correlazioni molto elevate** tra le feature morfologiche: in particolare **area-perimeter** ($r \approx 0.99$) e **length-width** ($r \approx 0.97$), suggerendo una forte ridondanza informativa tra variabili geometriche correlate.

Nei boxplot selezionati si può notare come le variabili **asymmetry_coefficient** e **compactness** mostrino dei valori anomali (seppur pochi)

Preprocessing

Rimozione Outlier (IQR)

Si usa l'**Interquartile Range** per individuare e rimuovere i valori anomali, mantenendo solo le osservazioni coerenti con la distribuzione dei dati.

Robust Scaling

Normalizzazione pensata per essere **resistente agli outlier**, perché utilizza statistiche robuste e limita l'influenza dei valori estremi.

Feature Engineering




Creazione di **due ratio features**: **Perimetro/Area**, che misura la compattezza della forma, e **Lunghezza/Larghezza**, che cattura il grado di allungamento del seme.

Riduzione Dimensionale

PCA per ottenere componenti ortogonali ordinate in base alla varianza spiegata, e rimozione della **multicollinearità** eliminando feature con $|r| > 0.85$.

K-Means Clustering

1. 4 modelli: PCA, rimozione multicollinearità, con e senza feature engineering.
2. Grid search: **n_clusters** [2,3,4,5,6,7,8], **init** ["k-means++"], **n_init** [10], **max_iter** [300].
3. Selezione del k ottimale con **Elbow Curve**.



Metriche di Valutazione dei Cluster



Silhouette Score

Misura coesione e separazione. Range: **$[-1, +1]$** . Valori vicini a +1 indicano cluster ben definiti e separati.



Davies-Bouldin Index

Rapporto dispersione intra-cluster / separazione inter-cluster. Range: **$[0, \infty)$** . Valori più bassi = cluster migliori.



Inertia (SSE)

Somma delle distanze quadrate dai centroidi. Usata nell'**Elbow Method** per scegliere k ottimale.



ARI

Adjusted Rand Index: confronta i cluster con le etichette reali. Range: **$[-1, +1]$** . Valori alti = accordo con la ground truth.

Confronto dei 4 Modelli

Modello	Silhouette ↑	Davies-Bouldin ↓	Inertia ↓	ARI ↑	n_clusters
PCA + K-Means	0.4309	0.8866	270.3240	0.4880	2
Multicollinearity + K-Means	0.3618	1.0260	121.3987	0.7019	3
FE + PCA + K-Means	0.3891	0.9636	244.7712	0.3407	2
FE + Multicollinearity + K-Means	0.4965	0.7180	185.1145	0.1522	2

Il modello FE + Multicollinearity + K-Means ottiene le migliori metriche interne (Silhouette $\approx$ 0.50, Davies-Bouldin 0.72), indicando cluster ben separati e coesi. Tuttavia, presenta il peggior ARI (0.15) poiché identifica solo 2 cluster anziché 3, come nella realtà. Questo trade-off riflette un limite intrinseco di K-Means: l'ottimizzazione della separazione geometrica non garantisce l'allineamento con la ground truth. La bassa separabilità delle classi nel dataset amplifica questo problema.

Sviluppi Futuri



Altri Algoritmi di Clustering

DBSCAN, Agglomerative Clustering e Gaussian Mixture Models per confrontare approcci basati su densità, gerarchia e distribuzione probabilistica.



API REST Completa

Estendere Flask con endpoint per previsioni on-demand, validazione input e documentazione OpenAPI/Swagger.



Ottimizzazione degli Iperparametri

GridSearch più ampia e RandomSearch per ottimizzare k, inizializzazione dei centroidi e parametri specifici di ciascun algoritmo.



Deployment su Cloud

Containerizzazione avanzata con Docker Compose e deployment su piattaforme cloud (AWS, GCP, Azure) con monitoraggio integrato.